

Rapport Compétition de données 1

Charlie Peng

8 November 2025

1 Informations sur l'équipe (1 membre)

Nom de l'équipe Kaggle: `ift3395_charlie_peng`

Membre d'équipe: Charlie Peng, Matricule: 20261217

2 Prétraitement des Caractéristiques

Certaines bières avaient des valeurs négatives proches de 0 pour les caractéristiques `lactic_acid` ou `sodium` qui sont supposé d'être des quantités. On a changé ces valeurs à 0, car des quantités négatives de substance dans une bière ne font pas de sens. On a enlevé les données ayant une ou plusieurs valeurs de caractéristique aberrantes. On a considéré les valeurs aberrantes comme celles qui semblaient éloignées des autres d'après les visualisations de distributions univariées faites lors de l'exploration. On fait cela, car on veut standardiser les données et la standardisation dépend de la moyenne et de la variance qui sont sensibles aux valeurs extrêmes. La standardisation a été faite pour s'assurer que les valeurs d'une caractéristique à l'autre soient dans la même échelle. Cela est important, car les valeurs de plus grande échelle peuvent dominer les autres pour certains algorithmes d'apprentissage (ex: KNN). Les caractéristiques choisies pour l'entraînement sont les suivants: `alcohol_ABV`, `final_gravity`, `dissolved_oxygen`, `lactic_acid`, `diacetyl_concentration`, `free_CO2`, `gypsum_level`. On les a choisi en se basant sur le score d'information mutuelle, qui permet de quantifier la relation entre une caractéristique et la cible. On a exclu `fermentation_strength`, car il est très fortement corrélé avec `alcohol_ABV` et son score d'information mutuelle est inférieur à celui de `alcohol_ABV`.

3 Méthodologie

On a mélangé les données, puis on les a divisé en un ensemble d'entraînement comportant 80% des données et un ensemble de validation contenant le 20% restant. Une graine aléatoire a été fournie pour garantir la reproductibilité. Le mélange est fait pour s'assurer que l'ordre initial des données ne pourrait pas affecter les résultats. On a évalué les algorithmes suivants: KNN, fenêtres de Parzen dures, Bayes naïf gaussien, régression logistique, analyse discriminante linéaire et SVM à marges molles. Ces derniers ont été vu en cours et avaient une implémentation dans la librairie `sklearn`. L'algorithme du centroïde le plus proche n'a pas été évalué, car il est trop simple. L'algorithme de régression linéaire n'a pas été évalué, car la régression logistique est similaire et cette dernière est plus robuste contre les valeurs éloignées. Pour les algorithmes ayant des hyperparamètres numériques (KNN, Parzen, régression logistique, SVM), on a entraîné et évalué chacun avec divers valeurs d'hyperparamètres et créé un graphe illustrant la performance en fonction de la valeur d'hyperparamètre. Les intervalles des valeurs d'hyperparamètres à évaluer ont été choisies en regardant le graphe de performance après plusieurs exécutions avec différents intervalles. Après avoir évalué tous ces différents configurations, on choisit celui ayant la meilleure précision (`accuracy`). Note: On va référer à la précision définie dans `README.md` comme "accuracy" dans le reste de ce rapport pour ne pas confondre avec le terme anglais "precision".

4 Résultat

Le classificateur ayant la plus grande accuracy est le classificateur 1-NN. Puisque 1-NN regarde le plus proche voisin parmi l'ensemble d'entraînement d'un point à prédire et le plus proche voisin de chaque point d'entraînement est lui-même, chaque observation d'entraînement sera correctement classifié. L'accuracy sur l'ensemble d'entraînement est donc 100%. Les métriques precision, recall et f1-score sont donc 100% pour chaque classe présente dans l'ensemble d'entraînement.

	precision	recall	f1-score	support
3	0.00	0.00	0.00	3
4	0.14	0.11	0.12	28
5	0.62	0.64	0.63	292
6	0.62	0.61	0.61	401
7	0.54	0.56	0.55	147
8	0.43	0.43	0.43	21
9	0.00	0.00	0.00	1
accuracy			0.59	893
macro avg	0.33	0.34	0.33	893
weighted avg	0.58	0.59	0.59	893

Figure 1: Métriques de performance sur l'ensemble de validation

D'après Figure 1, la performance sur l'ensemble de validation est beaucoup plus faible. Puisque 1-NN regarde un seul point d'entraînement, il est très sensible aux changements des données dans l'ensemble d'entraînement. 1-NN est donc susceptible de sur-apprendre les données d'entraînement, donc il généralisera beaucoup moins bien sur des données de validation, qui sont en dehors de cet ensemble.

	3	4	5	6	7	8	9
3	0	0	2	1	0	0	0
4	0	3	16	5	4	0	0
5	0	10	187	82	12	1	0
6	1	9	90	243	51	7	0
7	0	0	8	52	83	4	0
8	0	0	1	7	4	9	0
9	0	0	0	0	1	0	0

Figure 2: Matrice de confusion pour l'ensemble de validation

	3	4	5	6	7	8	9
3	0.0	0.00	0.67	0.33	0.00	0.00	0.0
4	0.0	0.11	0.57	0.18	0.14	0.00	0.0
5	0.0	0.03	0.64	0.28	0.04	0.00	0.0
6	0.0	0.02	0.22	0.61	0.13	0.02	0.0
7	0.0	0.00	0.05	0.35	0.56	0.03	0.0
8	0.0	0.00	0.05	0.33	0.19	0.43	0.0
9	0.0	0.00	0.00	0.00	1.00	0.00	0.0

Figure 3: Matrice de confusion normalisée pour l'ensemble de validation




Figure 4: Distribution des bières selon quality

D'après Figure 3 en regardant la diagonale, les classes quality les plus fréquemment mal classés sont 3 et 9. Cela est attendu, car se sont les deux classes les moins bien représentées dans l'ensemble de données (voir Figure 4). D'après Figure 2, les classes quality 5, 7 et 8 sont plus souvent mal classifiées comme étant 6 lorsqu'ils sont mal classifiées. Cela est possiblement en raison du fait que la classe quality 6 est la plus commune (voir Figure 4).

5 Discussion

Le score d'information mutuelle utilisé comme critère lors de la sélection de caractéristiques a l'avantage de pouvoir quantifier des relations non linéaires entre la cible et une caractéristique. Cependant, il ne tient pas compte des interactions entre les caractéristiques. Donc, la corrélation entre les paires des caractéristiques a aussi été utilisé pour réduire le risque de sélectionner des caractéristiques redondantes. Cependant la corrélation par paires ne capture pas les relations non linéaires et ni les interactions entre plus de deux caractéristiques. Le choix des valeurs d'hyperparamètre k pour KNN à évaluer a été assez simple puisque k est entier et ne devrait pas être trop grand par rapport à la taille de l'ensemble d'entraînement. Pour les algorithmes ayant des hyperparamètres continus comme Parzen, régression logistique et SVM, ce choix a été plus difficile à cause du manque de restriction (absence de limite, divers possibilités de taille de pas de variation pour l'hyperparamètre). On a dû faire plusieurs exécutions et regarder le graphe de performance et ajuster l'intervalle, ce qui implique un jugement subjectif. De plus, cela requiert beaucoup d'entraînements, ce qui est coûteux en temps, particulièrement pour les algorithmes longs à entraîner comme SVM. Pour SVM,

on n'a pas pu faire autant d'entraînement que les autres algorithmes en raison du temps d'entraînement requis et donc beaucoup moins de valeurs différentes de l'hyperparamètre C ont été évalué. On risque grandement de ne pas avoir choisi la valeur C qui résulterait en la performance optimale pour SVM.